Москва

23 августа

2025

Прогнозирование продаж товаров категории FMCG на основе ежедневных данных с помощью методов машинного обучения

Выполнила
DS-16 В.И. Вербицкая
Научный руководитель
Е.А. Паточенко

Основные положения

Цель исследования: Разработать надежную модель, предсказывающую продажи товаров, учитывающую сезонные колебания, наличие товаров на складе, цены и промоакции. Модель должна демонстрировать хорошую обобщающую способность как во времени, так и по категориям.

Предмет исследования: Продажи товаров категории FMCG в регионах Польши

Подход:

- Разведывательный анализ (EDA)
- Предиктивный анализ
- Предложения по дальнейшему развитию исследования

Результаты исследования могут быть полезны при планировании продаж, управлении запасами и организации маркетинговый акций

Данные

Источник данных: Kaggle - FMCG Daily Sales Data 2022-2024

Набор синтетических данных о ежедневных продажах товаров повседневного спроса (FMCG)

Размер датасета: **190 757** строк x **14** колонок

Временной интервал: с **21.01.2022** по **31.12.2024**

Целевой показатель: **units_sold (int)**

Нет пропущенных значений

Нет повторяющихся строк

Есть отрицательные значения: **stock_available, delivered_qty, units_sold**

Переменная	Описание
date	дата продажи
sku	идентификатор товара
brand	бренд товара
segment	сегмент товара
category	категория товара
channel	канал сбыта
region	регион продажи
pack_type	тип упаковки
price_unit	цена ед. товара
promotion_flag	флаг промоакции
delivery_days	доставка, дн.
stock_available	доступный запас, ед.
delivered_qty	доставлено, ед.
units_sold	продано, ед

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 190757 entries, 0 to 190756
Data columns (total 14 columns):
 #   Column           Non-Null Count   Dtype
---  ------           --------------   -----
 0   date             190757 non-null  object
 1   sku              190757 non-null  object
 2   brand            190757 non-null  object
 3   segment          190757 non-null  object
 4   category         190757 non-null  object
 5   channel          190757 non-null  object
 6   region           190757 non-null  object
 7   pack_type        190757 non-null  object
 8   price_unit       190757 non-null  float64
 9   promotion_flag   190757 non-null  int64
 10  delivery_days    190757 non-null  int64
 11  stock_available  190757 non-null  int64
 12  delivered_qty    190757 non-null  int64
 13  units_sold       190757 non-null  int64
dtypes: float64(1), int64(5), object(8)
memory usage: 20.4+ MB
(190757, 14)
```

Необходимо перевести data из строкового типа в datetime

	date	price_unit	promotion_flag	delivery_days	stock_available	delivered_qty	units_sold
count	190757	190757.000000	190757.000000	190757.000000	190757.000000	190757.000000	190757.000000
mean	2023-10-28 04:11:33.514785536	5.251979	0.149200	3.004860	157.697652	179.333655	19.919709
min	2022-01-21 00:00:00	1.500000	0.000000	1.000000	-12.000000	-11.000000	-25.000000
25%	2023-04-16 00:00:00	3.380000	0.000000	2.000000	124.000000	152.000000	12.000000
50%	2023-11-12 00:00:00	5.250000	0.000000	3.000000	155.000000	179.000000	18.000000
75%	2024-06-07 00:00:00	7.130000	0.000000	4.000000	192.000000	206.000000	25.000000
max	2024-12-31 00:00:00	9.000000	1.000000	5.000000	405.000000	366.000000	139.000000
std	NaN	2.166705	0.356287	1.414626	52.736104	40.037475	11.770077

	sku	brand	segment	category	channel	region	pack_type
count	190757	190757	190757	190757	190757	190757	190757
unique	30	14	13	5	3	3	3
top	MI-006	SnBrand2	Yogurt-Seg1	Yogurt	Retail	PL-North	Carton
freq	8221	26775	26851	72707	63688	63645	63671

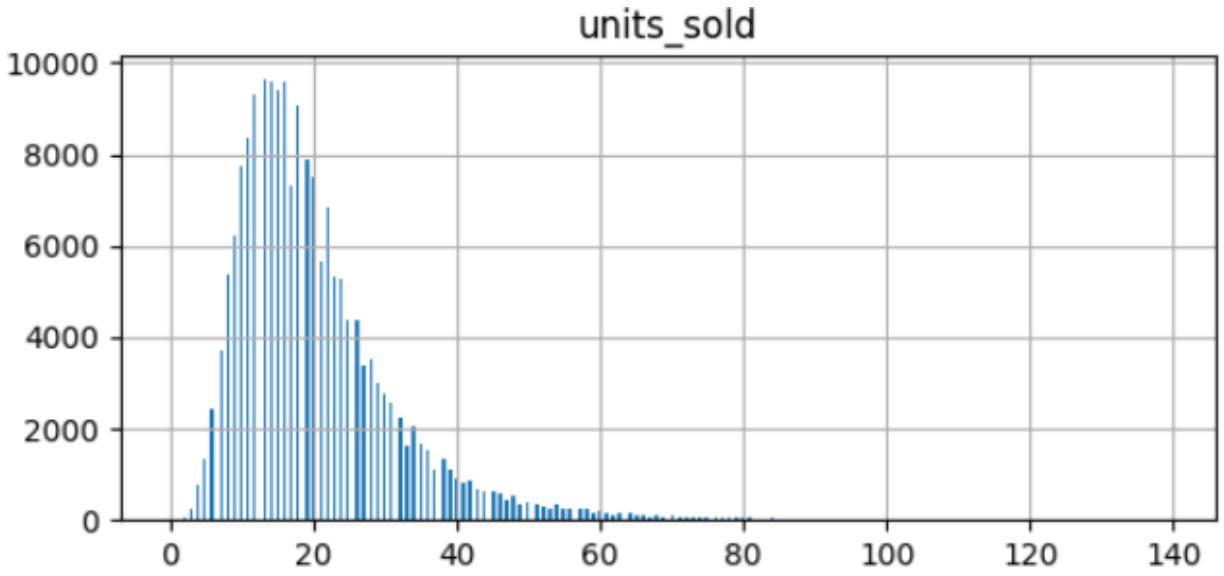
units_sold
10000
8000
6000
4000
2000
0
0
20
40
60
80
100
120
140

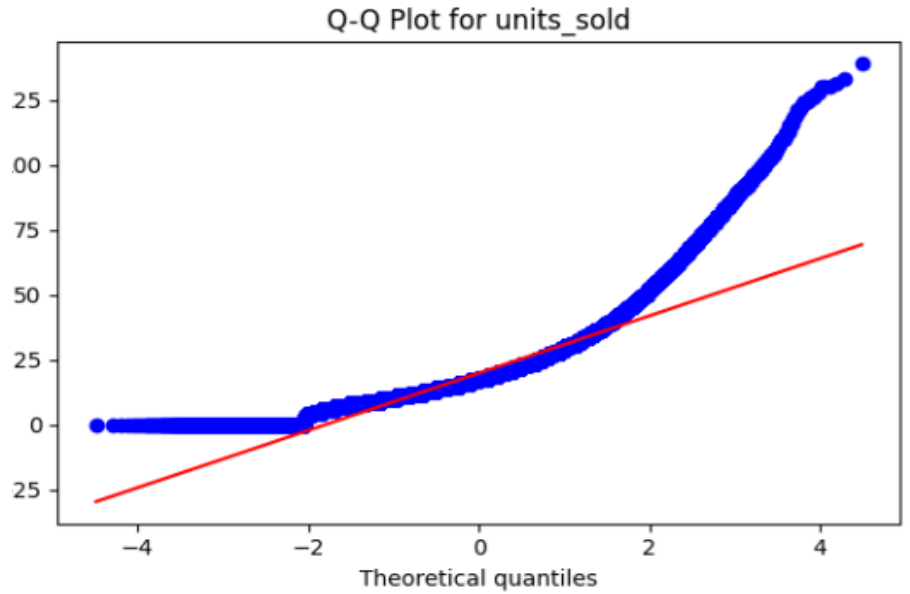
Q-Q Plot for units_sold
25
00
75
50
25
0
25
−4
−2
0
2
4
Theoretical quantiles

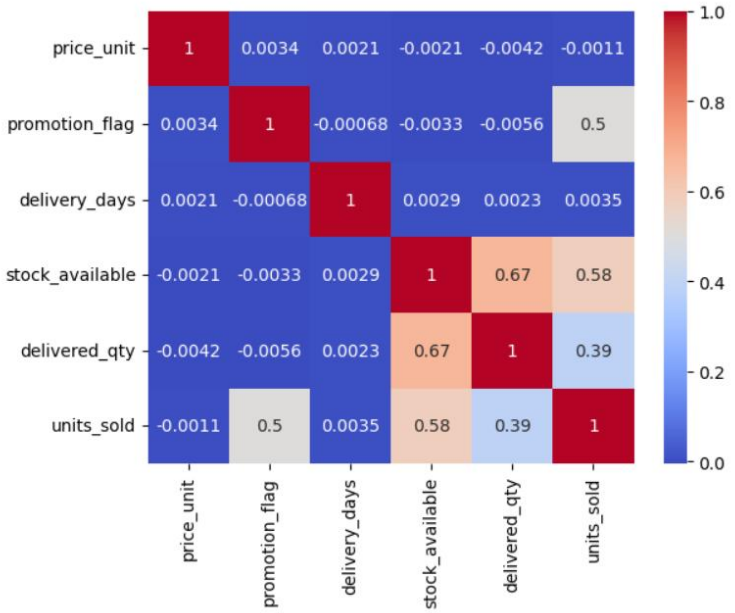

Признак	Корреляция	Доменная значимость (+/-)	Визуальный тренд	Оставить?
price_unit	~ 0.0	+	?	?
promotion_flag	0.50	+	нет	?
delivery_days	0.01	+	нет	?
stock_available	0.58	+	положит.	✅ Да
delivered_qty	0.39	+	положит.	✅ Да

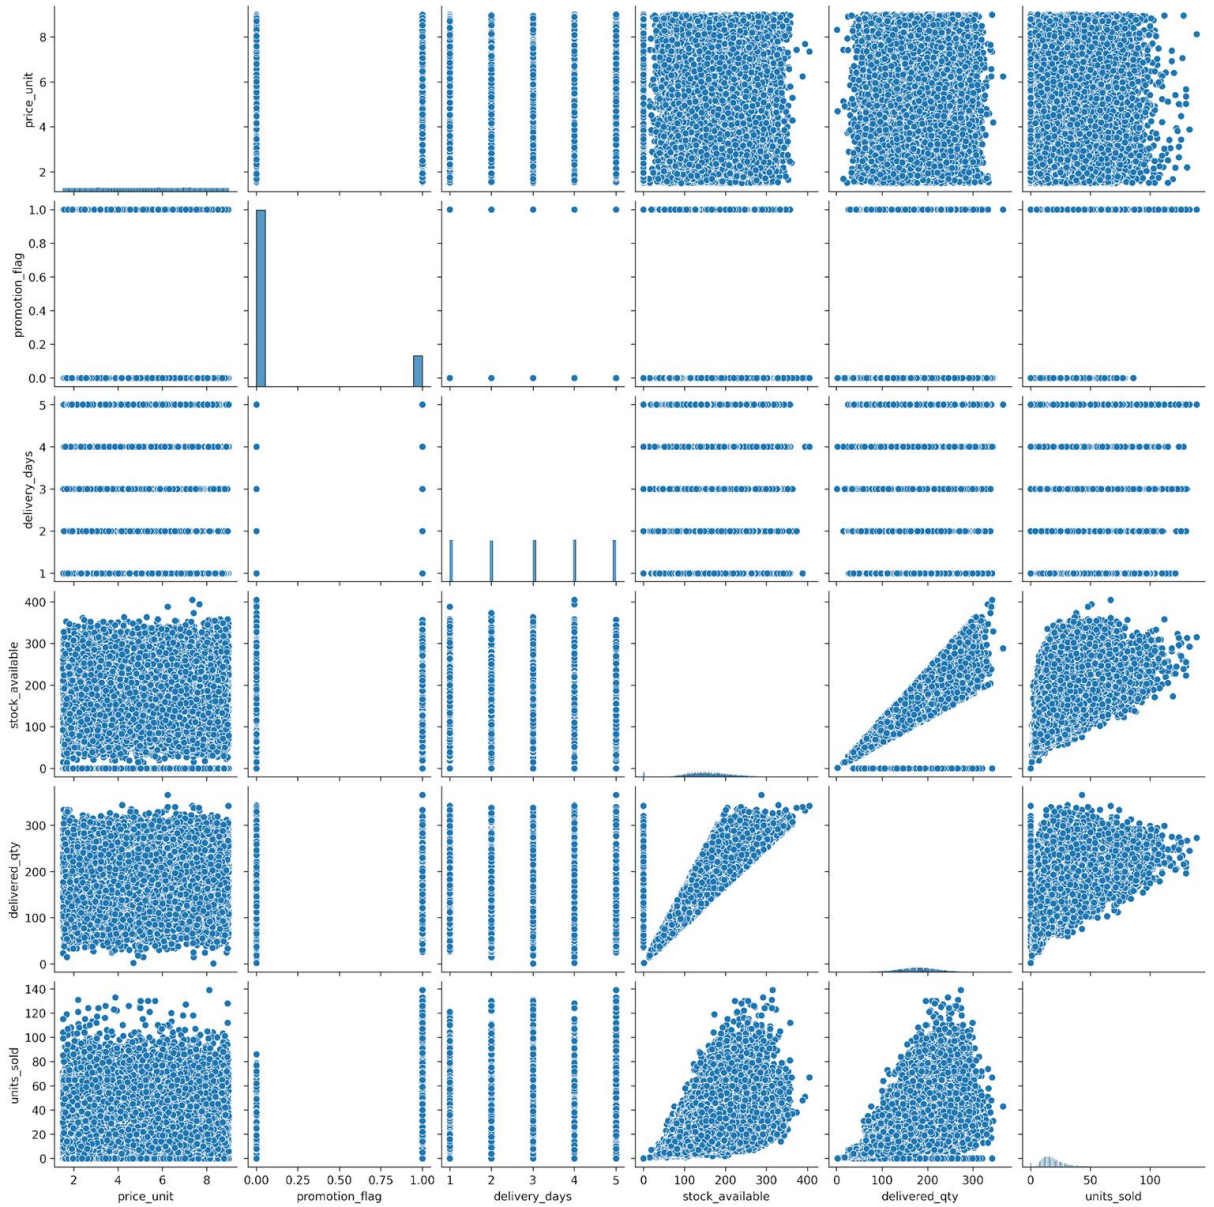

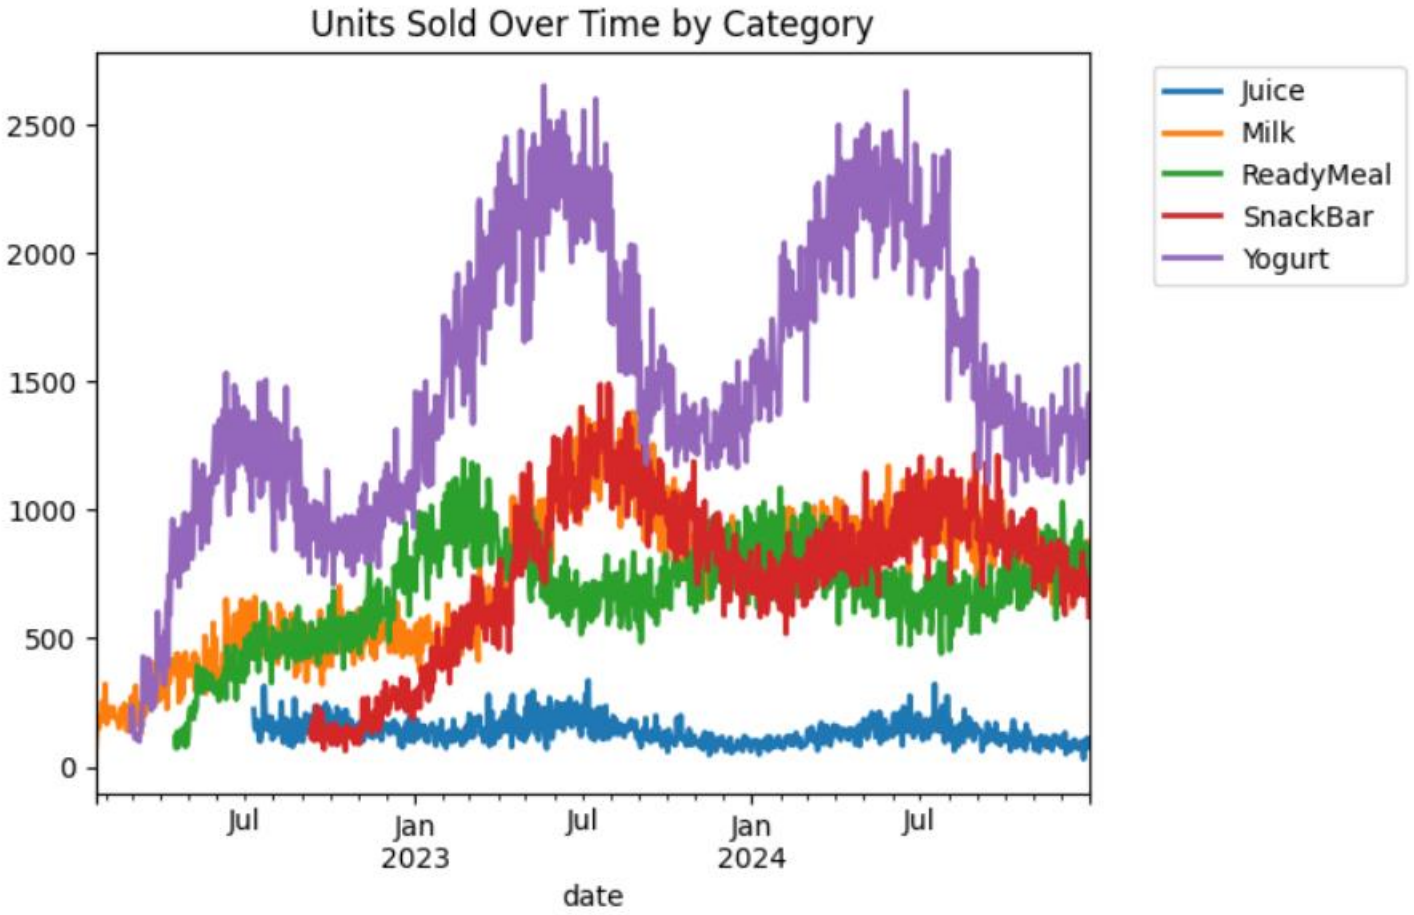
Units Sold Over Time by Category
2500
2000
1500
1000
500
0
Jul
Jan
2023
Jul
Jan
2024
Jul
date
Juice
Milk
ReadyMeal
SnackBar
Yogurt

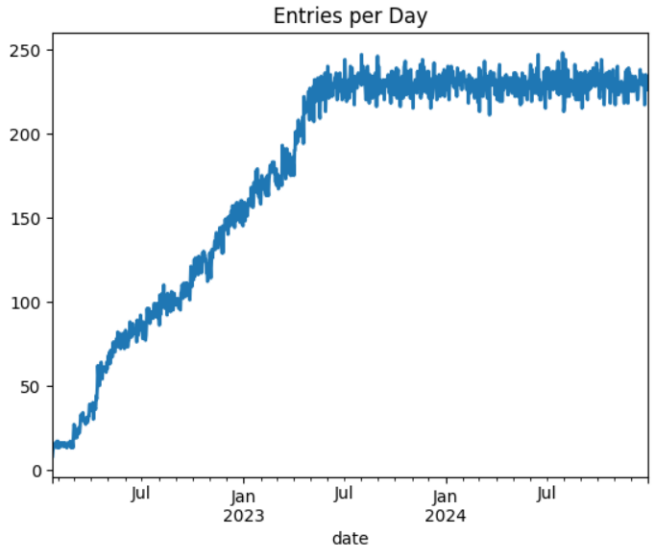
Entries per Day
250
200
150
100
50
0
Jul
Jan
2023
Jul
Jan
2024
Jul
date

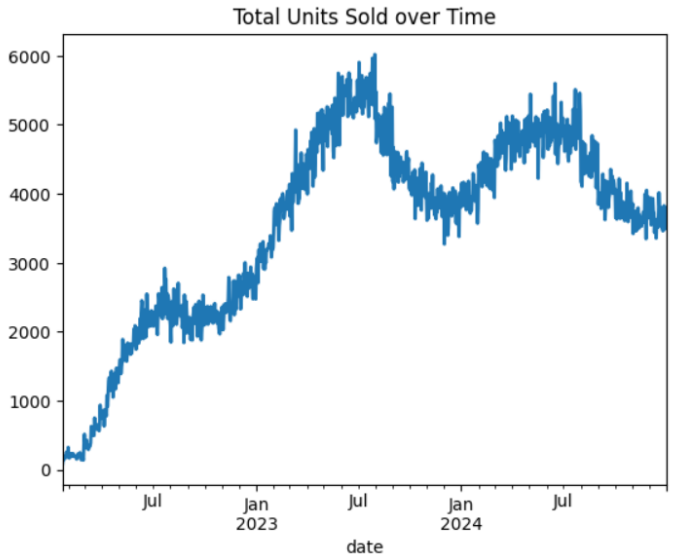
Total Units Sold over Time
6000
5000
4000
3000
2000
1000
0
Jul
Jan
2023
Jul
Jan
2024
Jul
date

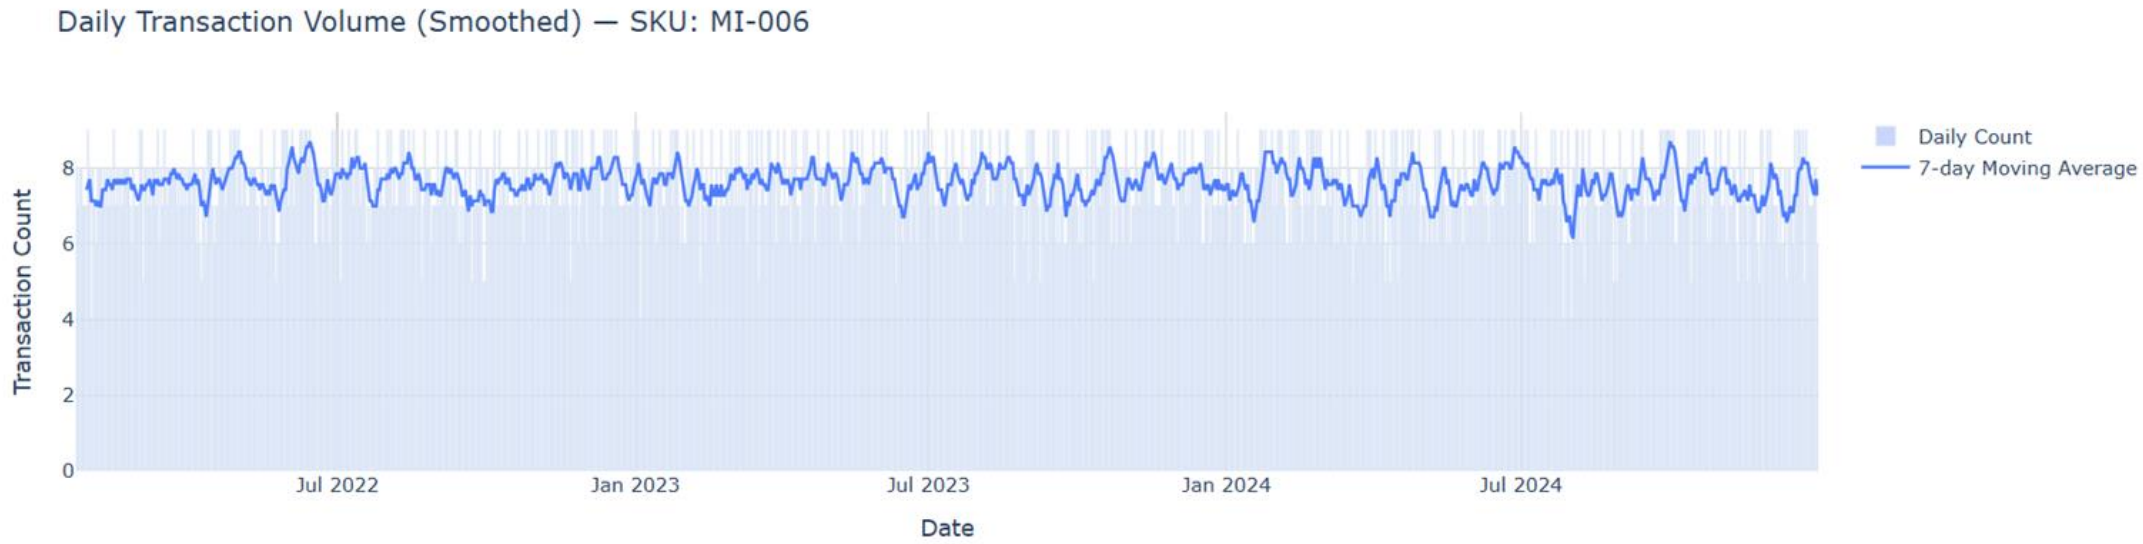
Daily Transaction Volume (Smoothed) — SKU: MI-006
Transaction Count
0
2
4
6
8
Jul 2022
Jan 2023
Jul 2023
Jan 2024
Jul 2024
Date
Daily Count
7-day Moving Average

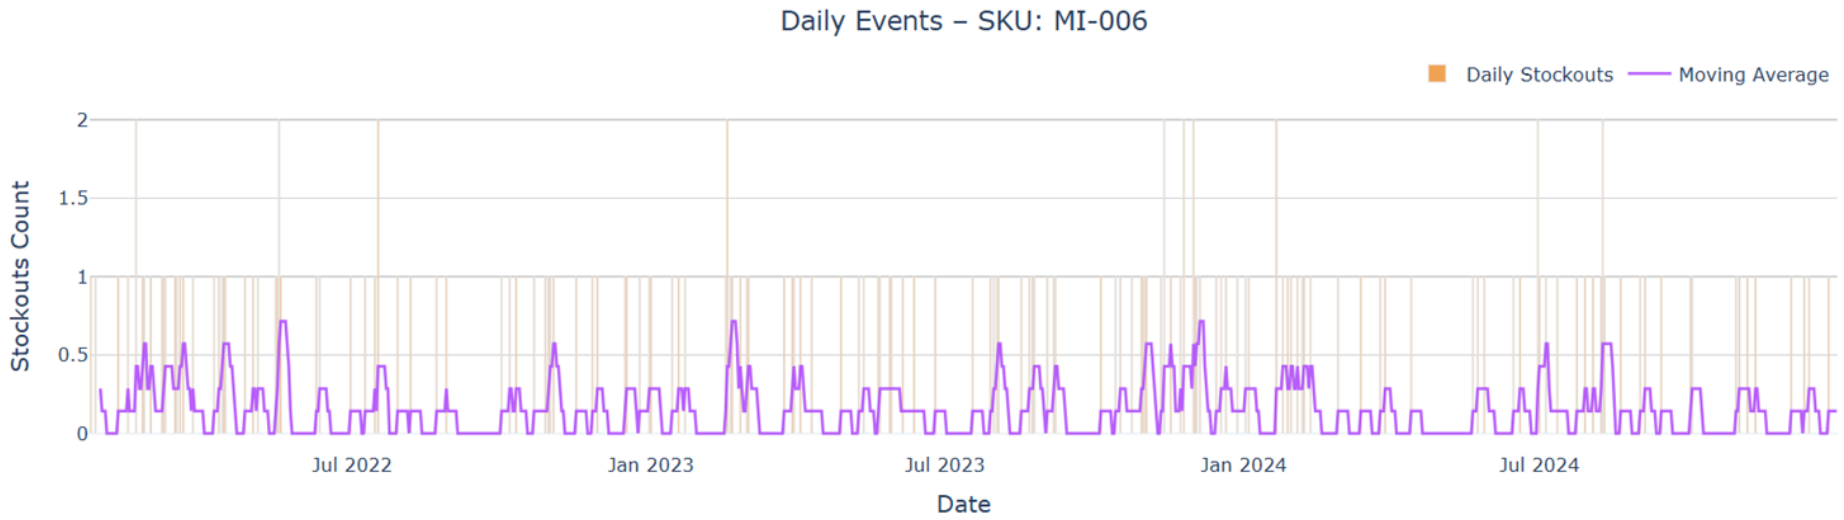
Daily Events – SKU: MI-006
Stockouts Count
0
0.5
1
1.5
2
Jul 2022
Jan 2023
Jul 2023
Jan 2024
Jul 2024
Date
Daily Stockouts
Moving Average

Новые переменные

1. Преобразование формата data из строкового типа в datetime
2. Преобразование категориальных переменных **'sku'**, **'segment'**, **'category'**
3. Создание новых переменных «календарь»: **'day'**, **'month'**, **'year'**, **'is_start_of_month'**, **'is_end_of_month'**, **'day_of_week'**, **'is_weekend'**, **'week_of_month'**
4. Кодирование запаздываний: лаг целевой переменной - **lag_1**, **lag_2**, **lag_3**, **lag_7**, **lag_14**, **lag_28** , **lag_1**, **lag_2**, **lag_3**, **lag_7**, **lag_14**, **lag_28** – лаг целевой переменной, **'momentum_7_1'**, **'momentum_14_7'** – коэффициент запаздывания, **'price_lag_1'**, **'promo_lag_1'**, **'promo_effect' = 'promotion_flag'* 'lag_1'**, **'delivery_lag_7'**, **'stock_lag_1'**, **'category_rolling_mean_7'**, **'category_rolling_std_7'**, **'price_rolling_mean_7'**, **'promo_rolling_7'**, **'stockout_flag'**, **'rolling_stockouts_7'**, **'time_since_promo'**, **'time_since_delivery'**
5. Сезонность: **'month_sin'**, **'month_cos'**, **'dow_sin'**, **'dow_cos'**
6. Перекрестный эффект: **'promo_dow'** = **'promotion_flag'* 'day_of_week'**; **'price_x_stock'** = **'price_unit'* 'stock_available'**

Модели

- Наивный прогноз
- MXGBoost / LightGBM
- Random Forest
- LSTM Sequence model

Наивный прогноз

Модель временного ряда, в которой его текущее значение равно предыдущему наблюдаемому значению этого ряда. «Наивная» модель — самый примитивный метод прогнозирования.
Описывается выражением:
$y(t+1)=y(t)$,
где $y(t)$ — последнее наблюдаемое значение, $y(t+1)$ — прогнозируемое значение.

```
baseline_df1 = df1.dropna(subset=['lag_1', 'units_sold']).copy()
baseline_df1['pred_baseline'] = baseline_df1['lag_1’]
```

📉 Baseline Model (Naive Forecast):
MAE: 10.86
RMSE: 15.24
R^2: -0.674
Отрицательный R^2 говорит о том, что выбранная модель не подходит для данных. Она не может уловить закономерности и предсказывает значения хуже, чем просто использование среднего значения целевой переменной. Поэтому применю для предсказания более сложную модель.

LightGBM

LightGBM была описана Голинь К., и соавт. в статье 2017 года под названием «LightGBM: A Highly Efficient Gradient Boosting Decision Tree».

- LightGBM

Столбцы, которые не будут использованы в качестве признаков для модели:

exclude_cols = ['date', 'sku', 'brand', 'segment', 'channel', 'region', 'pack_type', 'delivered_qty', 'units_sold', 'category']

Столбцы, которые будут использованы в качестве признаков для модели:

features = [col for col in df1.columns if col not in exclude_cols and not np.issubdtype(df1[col].dtype, np.datetime64)]

Из них являются категориальными:

categorical_features = ['sku_cat', 'segment_cat', 'category_cat','day_of_week', 'month', 'is_weekend', 'promotion_flag', 'is_start_of_month', 'is_end_of_month']

Целевая переменная:

target = 'units_sold'

LightGBM

- LightGBM

```
def train_and_evaluate_lgbm(X_train, X_test, y_train, y_test):
    model = lgb.LGBMRegressor(n_estimators=100, learning_rate=0.05, max_depth=5, random_state=42,
verbose=-1)
    model.fit(X_train, y_train)
    y_pred = model.predict(X_test)
```

📉 LightGBM Regressor Results:
MAPE: 0.22
SMAPE: 0.23
MAE: 3.54
RMSE: 5.00
R^2: 0.774

LightGBM

- LightGBM дополненная лагами и скользящими переменными:

```
for lag in lag_days: df1_lgbm[f'units_sold_lag_{lag}'] = (df1_lgbm.groupby(['channel', 'region'])['units_sold'].shift(lag))
for window in rolling_windows: df1_lgbm[f'rolling_mean_{window}'] = (
        df1_lgbm.groupby(['channel', 'region'])['units_sold']
        .shift(1).rolling(window=window).mean().reset_index(level=0, drop=True))
df1_lgbm[f'rolling_std_{window}'] = (df1_lgbm.groupby(['channel', 'region'])['units_sold']
        .shift(1).rolling(window=window).std().reset_index(level=0, drop=True))
```

📉 LightGBM Regressor Results:
MAPE: 0.22
SMAPE: 0.23
MAE: 3.57
RMSE: 5.03
R^2: 0.771

- Улучшения метрик не произошло

LightGBM

- LightGBM Extended Log-Transformed Target:

```
def train_lgbm_log_target(X_train, X_test, y_train,
y_test):
    y_train_log = np.log1p(y_train)
    y_test_log = np.log1p(y_test)
    model = LGBMRegressor(random_state=42)
    model.fit(X_train, y_train_log)
    y_pred_log = model.predict(X_test)
    y_pred = np.expm1(y_pred_log)
```

📉 LightGBM with Log1p Target:
MAPE: 0.21
SMAPE 0.23
MAE: 3.38
RMSE: 4.85
R^2: 0.788

LightGBM

- LightGBM+avg_by_channel_region

```
df1['avg_by_channel_region'] = (df1.groupby(['channel', 'region', 'date'])['units_sold'].transform('mean’))
```

📉 LightGBM Regressor Results:
MAPE: 0.20
SMAPE: 0.22
MAE: 2.78
RMSE: 3.99
R^2: 0.751

- Модель показала наилучшую среди LightGBM производительность

Random Forest

- Random Forest

```
rf_model = RandomForestRegressor(n_estimators=100,
    random_state=42)
rf_model.fit(X_train_rf, y_train_rf)
y_pred_rf = rf_model.predict(X_test_rf)
```

📉 Random Forest with Log1p Target:
MAPE: 0.5
SMAPE 0.39
MAE: 5.71
RMSE: 6.86
R²: 0.263

- Random Forest GridSearchCV

```
y_train_rf_log = np.log1p(y_train_rf)
param_grid = {
    'n_estimators': [100, 200],
    'max_depth': [5, 10, None],
    'min_samples_split': [2, 5],
    'min_samples_leaf': [1, 2],
    'max_features': ['sqrt', 0.8]
}
rf = RandomForestRegressor(random_state=42, n_jobs=-1)
grid_search = GridSearchCV(
    estimator=rf,
    param_grid=param_grid,
    scoring='neg_mean_absolute_error',
    cv=3,
    verbose=1,
    n_jobs=-1
)
grid_search.fit(X_train_rf, y_train_rf_log)
grid_search.best_params_, grid_search.best_score_best_rf_log =
        grid_search.best_estimator_
y_pred_best_rf_log = best_rf_log.predict(X_test_rf)
y_pred_best_rf = np.expm1(y_pred_best_rf_log)
```

📉 Best Random Forest (GS):
MAPE: 0.44
SMAPE 0.33
MAE: 4.99
RMSE: 6.22
R²: 0.393

LSTM Sequence model

```
model = tf.keras.Sequential()
model.add(tf.keras.layers.LSTM(32, activation='relu', input_shape=(X_train_lstm.shape[1], X_train_lstm.shape[2])))
model.add(tf.keras.layers.Dense(1, activation='relu'))
model.compile(optimizer='adam', loss='mean_squared_error’)
model.fit(X_train_lstm, y_train_lstm, epochs=100,batch_size=32,
    callbacks=[EarlyStopping(patience=10, restore_best_weights=True)],
    verbose=1)
```

📉 LSTM Results:
MAE: 7.25
RMSE: 10.24
R^2: 0.053

Результаты исследования

Вариант модели	MAE	RMSE	R^2
Наивный прогноз	10.86	15.24	-0.674
LightGBM Regressor	3.54	5.00	0.774
LightGBM Extended	3.57	5.03	0.771
LightGBM Extended Log-Transformed Target	3.38	4.85	0.788
LightGBM+avg_by_channel_region	2.78	3.99	0.751
Random Forest	5.71	6.86	0.263
RF GridSearchCV	4.99	6.22	0.393
LSTM Sequence model	7.38	10.35	0.032

Результаты исследования

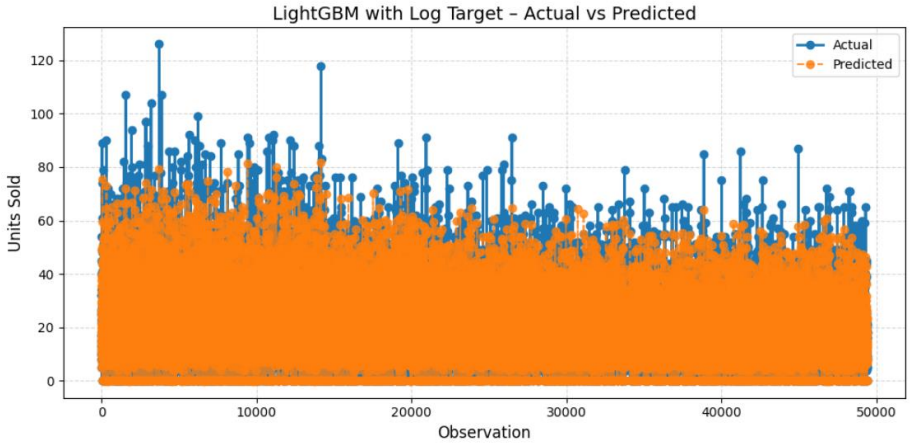

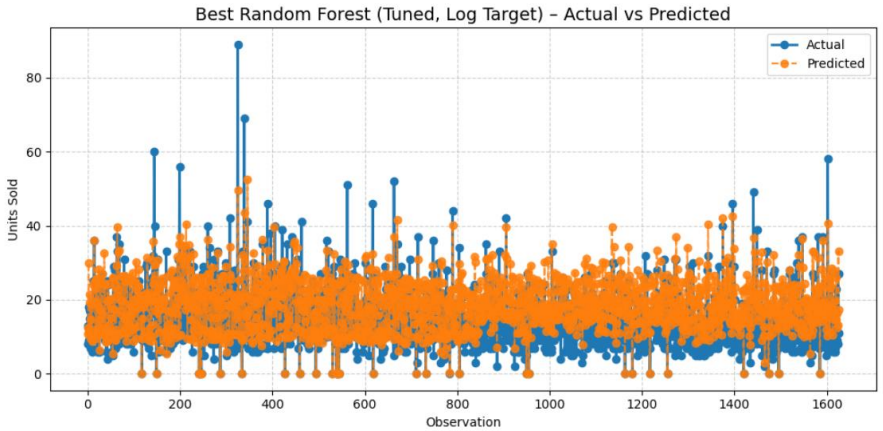

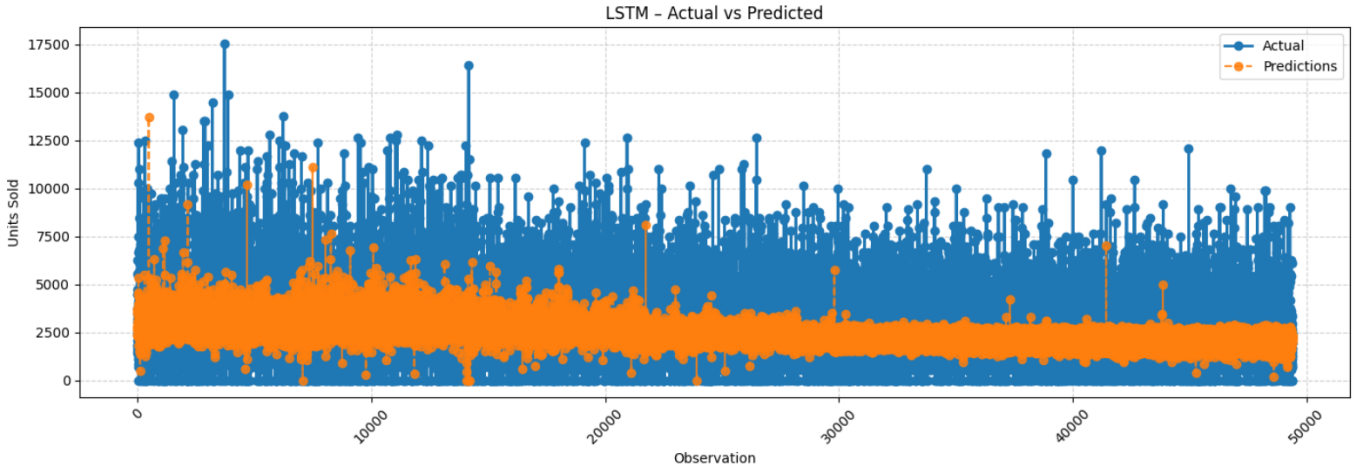

Выводы

- Предсказанные моделями значения в разной степени отражают тенденции продаж
- Лучшую производительность среди примененных показала модель вида LightGBM
- Лучший результат среди моделей LightGBM - у модели с дополнительным параметром avg_by_channel_region
- Худший результат – у наивного прогноза и LSTM
- Чтобы исключить отрицательные значения в прогнозных данных модели LSTM необходимо использовать функцию активации ReLU (Rectified Linear Unit) в последнем слое модели

Продолжение исследования

- Изменить глубину прогноза до еженедельных и ежеквартальных продаж.
- Для улучшения качества прогноза LSTM более детально подбирать параметры модели
- Применить гибридные модели, которые основаны на усредненных предсказаниях ранее используемых мной моделей.
- Использовать возможности библиотеки Prophet для прогнозирования (Sean J. Taylor, Benjamin Letham *"Forecasting at scale"*)
- Выполнить прескриптивный анализ, используя машинное обучение с подкреплением (RL), для автоматизации процесса принятия решений на основе созданных прогнозов


ВЫСШАЯ • ШКОЛА • ЭКОНОМИКИ •